

6. Bài tập tính toán

Bài 1

Corpus:

the cat eats fish
the dog eats fish
the cat likes milk
the dog likes meat

Thứ tự các chiều của vector:

[cat, dog, eats, likes, fish, milk, meat]

Với window = 1, xét một từ liền trước và sau từ mục tiêu trong cùng câu. Mỗi lần xuất hiện của context được cộng 1. Từ the không thuộc vocabulary nên không được tính.

Mỗi hàng là vector của một từ mục tiêu:

	cat	dog	eats	likes	fish
cat	0	0	1	1	0
dog	0	0	1	1	0
eats	1	1	0	0	2
likes	1	1	0	0	0

Từ eats đứng cạnh cat 1 lần, dog một lần và fish hai lần, nên có vector $[1, 1, 0, 0, 2, 0, 0]$.

Bài 2

$$\cos(x, y) = \frac{x \cdot y}{\|x\| \cdot \|y\|}$$

Với $x = [1, 2, 1]$, $y = [2, 4, 2]$

$$\cos(x, y) = \frac{1 \cdot 2 + 2 \cdot 4 + 1 \cdot 2}{\sqrt{1^2 + 2^2 + 1^2} \cdot \sqrt{2^2 + 4^2 + 2^2}} = \frac{10}{\sqrt{6} \cdot \sqrt{24}} = 1$$

Vì $y = 2x$, hai vector cùng hướng, có góc giữa chúng bằng 0° . Cosine similarity chỉ đo sự tương đồng về hướng, nên dù độ dài của y gấp đôi x kết quả vẫn bằng 1

7. Bài 3: So sánh semantic similarity.
 Dữ liệu: physician gần doctor hơn vì cả 2 đều nói về bác sĩ, còn banana là quả.
 1. Doctor và physician

$$\cos(\text{doctor}, \text{physician}) = \frac{0,8 \cdot 0,7 + 0,1 \cdot 0,2 + 0,7 \cdot 0,8}{\sqrt{0,8^2 + 0,1^2 + 0,7^2} \cdot \sqrt{0,7^2 + 0,2^2 + 0,8^2}} = 0,9671$$

2. Doctor và banana

$$\cos(\text{doctor}, \text{banana}) = \frac{0,8 \cdot (-0,2) + 0,1 \cdot 0,9 + 0,7 \cdot (-0,1)}{\sqrt{0,8^2 + 0,1^2 + 0,7^2} \cdot \sqrt{(-0,2)^2 + (0,9)^2 + (-0,1)^2}} = -0,1414$$

physician gần doctor hơn vì cosine similarity lớn hơn và gần 1. Kết quả phù hợp với dữ liệu ban đầu

8. Bài 4. - Sparse vs dense

1. word-context representation là sparse vì chỉ có 30 thành phần khác 0 trong 10000 từ, 0,3%. Các thành phần còn lại đều bằng 0

2. Embedding 300 chiều là dense vì hầu hết các thành phần khác 0

3. Embedding được học có thể biểu diễn các đặc điểm chung của những từ xuất hiện trong context tương tự. Vì vậy, hai từ vẫn có thể có vector gần nhau dù không có context trùng khớp hoàn toàn

Lỗi về này phụ thuộc vào cách huấn luyện và dữ liệu, không chỉ vào việc vector có nhiều thành phần khác không

4. Không, chất lượng phụ thuộc vào dữ liệu và mục tiêu bài toán. Embedding có thể học kém khi dữ liệu ít hoặc xuất hiện quá hiếm. Biểu diễn sparse như TF-IDF vẫn hữu ích khi cần tìm đúng từ khóa và để giải thích kết quả. Vì vậy cần đánh giá trên bài toán cụ thể để lựa chọn biểu diễn phù hợp.

23. Bài tập tính analogy

$$\begin{aligned}\text{king} - \text{man} + \text{woman} &= [8, 2, 7] - [5, 1, 5] + [5, 3, 5] \\ &= [8-5+5, 2-1+3, 7-5+5] = [8, 4, 7]\end{aligned}$$

Hiệu $\text{woman} - \text{man} = [0, 2, 0]$ có thể biểu diễn quan hệ từ nam sang nữ. Khi cộng hiệu này vào vector king , vector mới có thể đại diện cho queen theo analogy.

$$\text{man} : \text{woman} \approx \text{king} : \text{queen}$$

Đây là cách diễn giải đúng; muốn xác định cần so sánh vector mới với vector của queen và các từ khác.