

25. Exact analysis

A. Ba trường hợp similarity hợp lý

1. Doctor - physician

- Observed: physician đứng top 1 của doctor với cosine = 0,7251
- Expected: Hai từ có similarity cao vì đều chỉ bác sĩ
- Possible explanation: Chúng xuất hiện trong các context tương tự vì chẩn bác khác nhau
- Evidence from corpus: Context chung gồm case với số lần 9/13, health 8/5 và medical 5/6 tương ứng với doctor/physician. Doc 169, câu 36 có cụm "primary case physician"; Doc 2980, câu 3 có cụm "A medical doctor"

2. Hospital - clinic

- Observed: clinic đứng top 1 của hospital, cosine = 0,7308
- Expected: Hai từ gần nhau vì đều chỉ cơ sở cung cấp dịch vụ y tế
- Possible explanation: Các context chung liên quan đến bác khác, chẩn bác và cơ sở điều trị
- Evidence from corpus: Context chung gồm health 15/8 và case 14/7 tương ứng với hospital/clinic. Doc 455 có cụm "Pre-Hospital Health case"; Doc 3063 có cụm "Alternative Back Case Clinic"

3. Computer - desktop

- Observed: desktop đứng top 2 của computer, cosine = 0,6792
- Expected: Hai từ có similarity cao vì desktop có thể chỉ máy tính để bàn
- Possible explanation: Chúng cũng xuất hiện trong context về thiết bị và ứng dụng máy tính
- Evidence from corpus: Doc 2150 câu 5 có chứa cụm "desktop computer". Context chung gồm laptop 13/7 và mobile 7/7 tương ứng computer/desktop

B. Ba trường hợp similarity bất ngờ

4. Football - replica

- Observed: replica đứng top 1 của football, cosine = 0,7932
- Expected: Kỳ vọng các từ liên quan trực tiếp đến thể thao như team, match hoặc player
- Possible explanation: Đã liên nhiên và các cụm từ lặp lại có thể làm model học nhầm context về áo bóng đá
- Evidence from corpus: Doc 6083 lặp nhiều cụm "replica football shirt". Riêng document này chứa 344/573 lần xuất hiện của football và 163/183 lần xuất hiện của replica trong toàn corpus. Điều này cho thấy context bị tập trung mạnh vào một tài liệu

5. Hospital - emoji

- Observed: emoji đứng top 3 của Hospital, cosine = 0,6345
- Expected: kỳ vọng các từ mang ý nghĩa y tế chung hơn là một tên riêng
- Possible explanation: emoji xuất hiện ít và một phần context gần với tên bệnh viện, nên vector có thể gần hospital
- Evidence from corpus: emoji chỉ xuất hiện 8 lần. Doc 5138 có câu "welcome to Emory Johns creek Hospital" và lặp tên bệnh viện này ở các câu khác. Đây là kết quả bất ngờ, nhưng có liên hệ thực tế - body corpus

6. Banana - mug

- Observed: mug đứng top 6 của Banana, cosine = 0,7024
- Expected: kỳ vọng những từ liên quan đến trái cây hoặc thực phẩm hơn là cốc uống nước
- Possible explanation: ~~Đầu~~ Từ xuất hiện vì một bộ context về đồ ăn, đồ uống có thể ảnh hưởng đến kết quả
- Evidence from corpus: banana xuất hiện 42 lần, mug chỉ 1 lần. Context chung gần bộ lọc chỉ có coffee, với số lần 1/2. Doc 2512 có cụm "coffee festivals, banana festivals". Doc 1043 có cụm "coffee mugs and mugs". Bằng chứng này còn ít, nên chưa đủ để khẳng định nguyên nhân

Kết luận: cosine có thể phản ánh sự gần nghĩa, cũng như thể hiện các context lặp lại trong dữ liệu. Vì vậy cần kết hợp thêm similarity với tần suất và nội dung corpus khi đánh giá. Các nguyên nhân này đều là những giả thiết, cần được chứng minh rõ ràng.

26. Polysemy

Từ bank có hai nghĩa trong hai câu

- "I deposited money in the bank" : bank có nghĩa là ngân hàng
- "we sat on the river bank" : bank nghĩa là bờ sông

Static word 2 vec chỉ học một vector duy nhất cho bank từ tất cả context chứa từ này. Vector có thể phản ánh cả hai nghĩa hoặc nghiêng về nghĩa xuất hiện thường xuyên hơn trong corpus

Tuy nhiên, vector của bank vẫn giống nhau trong cả hai câu nên không thể hiện được nghĩa phù hợp với từng lần sử dụng. Đây là giới hạn của static vector embedding khi xử lý đa nghĩa

Contextual embedding khắc phục giới hạn này bằng cách biểu diễn phụ thuộc vào câu giúp phân biệt bank trong context tài chính và bank trong context sông nước