10. Prediction trước experiment

Prediction 1:

Prediction: TF-IDF kết hợp Logistic Regression có khả năng hoạt động tốt trên dataset IMDb và [redacted] là một baseline phù hợp cho bài toán sentiment classification

Reason: Review phim thường chứa những từ thể hiện cảm xúc như "excellent", "amazing", "terrible" hoặc "boring". TF-IDF giữ thông tin về các từ xuất hiện trong văn bản và giảm trọng số của các từ phổ biến trên nhiều tài liệu. Logistic Regression có thể học trọng số của các feature để phân biệt review positive và negative. Tuy nhiên, mô hình vẫn có thể gặp khó khăn với phủ định, mỉa mai và những câu cần hiểu ngữ cảnh

Confidence: Cao

Prediction 2:

Prediction: Average Word2vec không chắc chắn tốt hơn TF-IDF. Với bài toán sentiment classification trên IMDb, TF-IDF kết hợp Logistic Regression có thể đạt kết quả tốt hơn Average Word2vec kết hợp Logistic Regression

Reason: Word2vec biểu diễn thông tin ngữ cảnh của từ, nhưng phép lấy trung bình làm mất thứ tự từ và có thể làm giảm ảnh hưởng của những từ quan trọng đối với nhãn. Ví dụ, thông tin phủ định trong "not good" có thể không được thể hiện rõ khi vector của "not" và "good" chỉ được cộng vào vector trung bình. TF-IDF giữ các feature riêng biệt, giúp classifier học trực tiếp mối liên hệ giữa từng từ và sentiment.

Confidence: Trung bình

Prediction 3:

Prediction: Tăng vocabulary size không đảm bảo accuracy tăng

Reason: Vocabulary lớn hơn có thể giữ lại nhiều từ hữu ích, nhưng cũng có thể bị sung từ nhiễu, lỗi chính tả và các feature ít liên quan đến nhãn. Những feature này làm tăng số chiều, chi phí tính toán và có thể khiến model học các điểm riêng của tập train. Vì vậy, cần chọn vocabulary size hoặc tham số min_df dựa trên kết quả validation thay vì chỉ cố gắng tăng số lượng feature

Confidence: Cao

Được quét bằng CamScanner

Prediction 4:

Prediction: loại bỏ stopwords không chắc cải thiện performance, có thể làm giảm chất lượng sentiment classification

Reason: loại bỏ các từ ít mang thông tin có thể giảm kích thước vocabulary và giúp xử lý nhanh hơn. Tuy nhiên, một số danh sách stopwords chứa các từ phủ định như "not" hoặc "no". Nếu loại bỏ các từ này, câu "not good" có thể mất thông tin phủ định quan trọng. Do đó, cần kiểm tra danh sách stopwords và so sánh kết quả trên validation trước khi quyết định sử dụng

confidence: Trung bình

Prediction 5:

Prediction: Accuracy và F_1 có thể đánh giá những khía cạnh khác nhau về chất lượng của model, đặc biệt là dữ liệu mất cân bằng

Reason: Accuracy đo tỉ lệ dự đoán đúng trên toàn bộ mẫu, nên có thể cao khi model chủ yếu dự đoán đúng lớp chiếm đa số. F_1 của class positive kết hợp precision và recall, giúp phản ánh khả năng phát hiện lớp này. Một model có thể đạt accuracy cao nhưng F_1 thấp nếu bỏ sót nhiều mẫu positive. Vì vậy, cần đánh giá accuracy, precision, recall, F_1 và confusion matrix để đánh giá model đầy đủ

confidence: Cao

Được quét bằng CamScanner