Reflection

1. Những gì em học được

Qua bài lab này, em hiểu được quy trình xây dựng hệ thống phân loại văn bản:
Văn bản gốc → tiền xử lý → biểu diễn số → huấn luyện mô hình → dự đoán → đánh giá
Em đánh giá nhận thấy kết quả của mô hình phụ thuộc vào cách biểu diễn văn bản và classifier được sử dụng

2. Chia dữ liệu và data leakage

Dữ liệu được chia thành 3 tập: train, validation và test. Tập train để huấn luyện mô hình, tập validation dùng để chọn tham số, tập test chỉ dùng để đánh giá cuối cùng
TF-IDF chỉ được học trên tập train. Nếu fit TF-IDF trên toàn bộ dữ liệu trước khi chia tập dữ liệu thì sẽ xảy ra data leakage, vì sử dụng thông tin từ validation và test để được sử dụng trong quá trình huấn luyện

3. So sánh TF-IDF và Average Word2Vec

Kết quả thực nghiệm, các mô hình sử dụng TF-IDF phù hợp với bài toán sentiment classification hơn Average Word2Vec
Các review phim thường chứa những từ thể hiện cảm xúc như "excellent", "amazing" "terrible" và "boring". TF-IDF giữ được những từ hoặc cụm từ quan trọng này nhờ đó classifier có thể giữ được mối liên hệ giữa feature và nhãn sentiment.
Average Word2Vec công trung bình nên làm mất đi thứ tự và ngữ cảnh.

4. Hạn chế về thứ tự từ và từ phủ định

Average Word2Vec có thể coi các vector gần nhau những câu như:
"this movies is good" và "this movies is not good"
Nguyên nhân là các vector của từ chỉ được cộng và lấy trung bình. Từ "not" có thể không đủ ảnh hưởng để thay đổi toàn bộ vector câu

5. So sánh unigram và bigram

Việc thêm bigram giúp mô hình nhận biết được những cụm từ như "not good", "very good" hoặc "really bad".
Bigram có thể giúp cải thiện ~~mô hình~~ khả năng phân loại vì giữ được 1 phần thông tin về các từ đứng cạnh nhau.

Được quét bằng CamScanner

6. Đánh giá và phân tích lỗi:

Accuracy không đủ để đánh giá một mô hình. Vì vậy sử dụng thêm precision, recall f1-score và confusion matrix.

Confusion matrix giúp biết số lượng mẫu dự đoán đúng và số lượng mẫu bị dự đoán nhầm giữa các class

7. Hạn chế và hướng phát triển

Các mô hình trong bài vẫn còn 1 số hạn chế. TF-IDF chỉ gán dựa trên sự xuất hiện của từ và chưa hiểu được ngữ nghĩa sâu. Average Word2Vec làm mất thứ tự từ và không tìm ngữ cảnh

Trong tương lai có thể sử dụng các mô hình như Transformer để tăng khả năng hiểu và nắm bắt được ngữ cảnh hơn

8. Kết luận

Bài lab giúp em hiểu rằng ~~representation~~ representation có ảnh hưởng đến kết quả phân loại văn bản. với ~~IMDB~~ IMDb, TF-IDF hoạt động tốt vì review chứa nhiều từ và cụm từ thể hiện cảm xúc

Cần xem xét nhiều metric, confusion matrix thay vì chỉ nhìn vào accuracy

9. AI Assistance Statement

Em sử dụng chat GPT để debug code, tạo visualization.

Được quét bằng CamScanner